

رسالة محمد

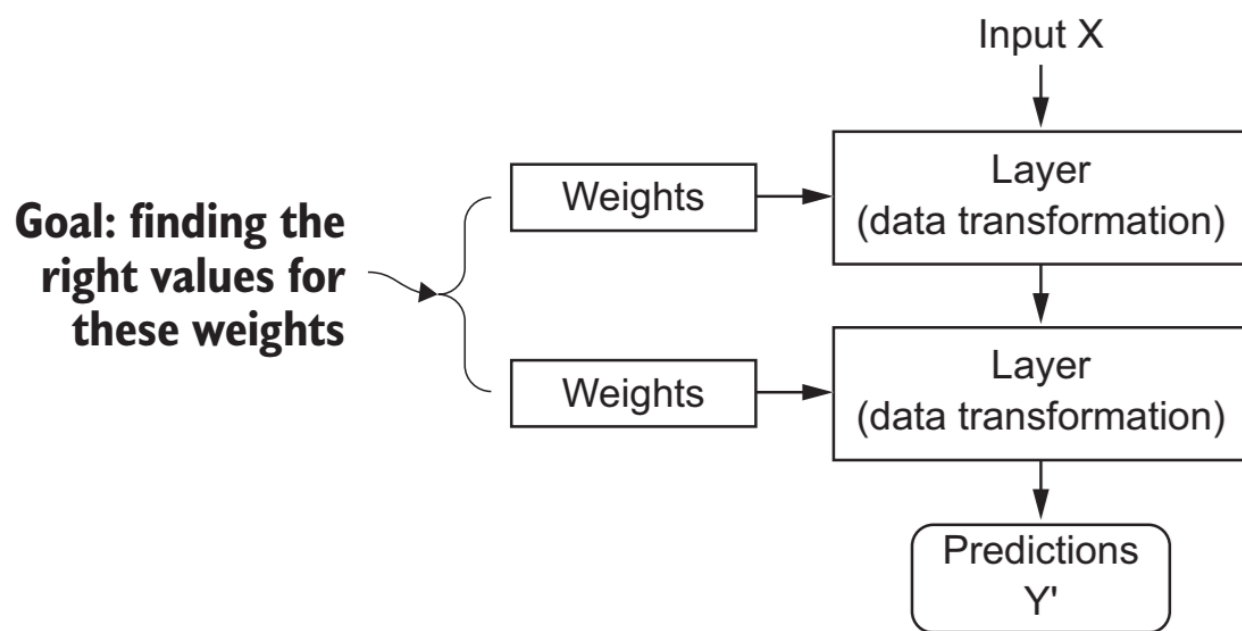
مبانی یادگیری عمیق

مدرس: محمدرضا محمدی

۱۴۰۰

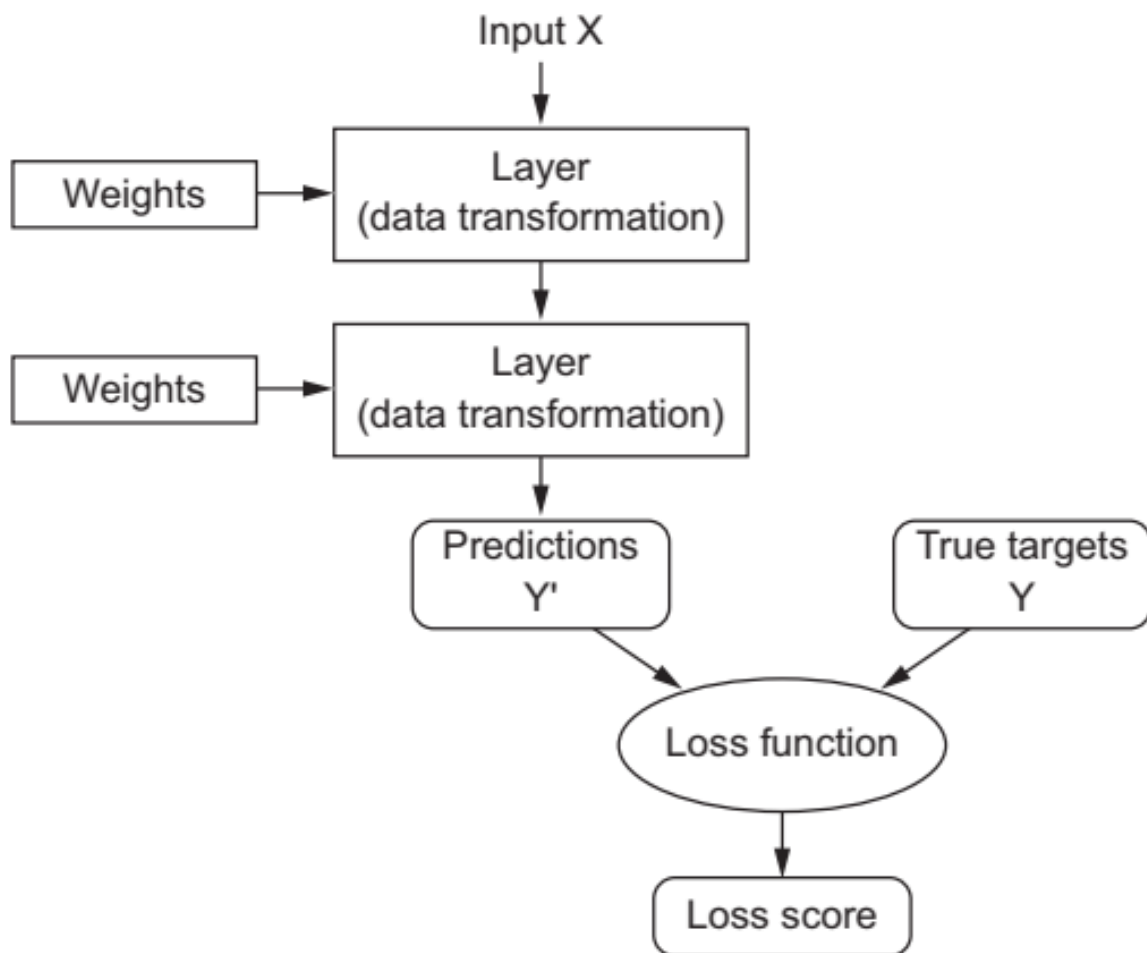
یادگیری عمیق

- یادگیری عمیق به دنبال یافتن یک نگاشت از ورودی‌ها به خروجی‌های مطلوب است
 - این یادگیری از طریق مشاهده نمونه‌های بسیار زیاد از ورودی‌ها و خروجی‌ها حاصل می‌شود
- نیاز است تا وزن‌های تمام لایه‌های شبکه به گونه‌ای تنظیم شوند که بتواند ورودی‌های نمونه را به خروجی‌های مربوطه نگاشت کند



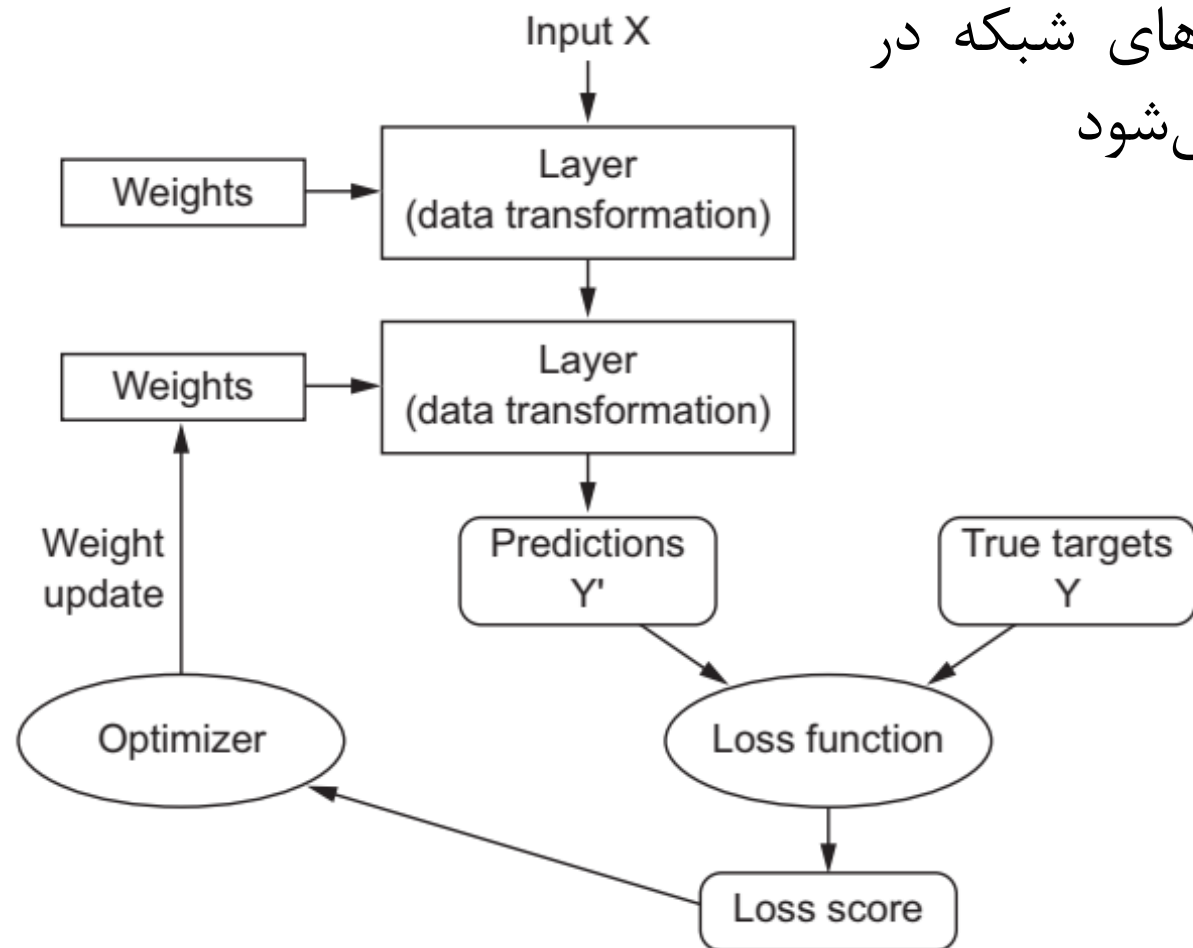
یادگیری عمیق

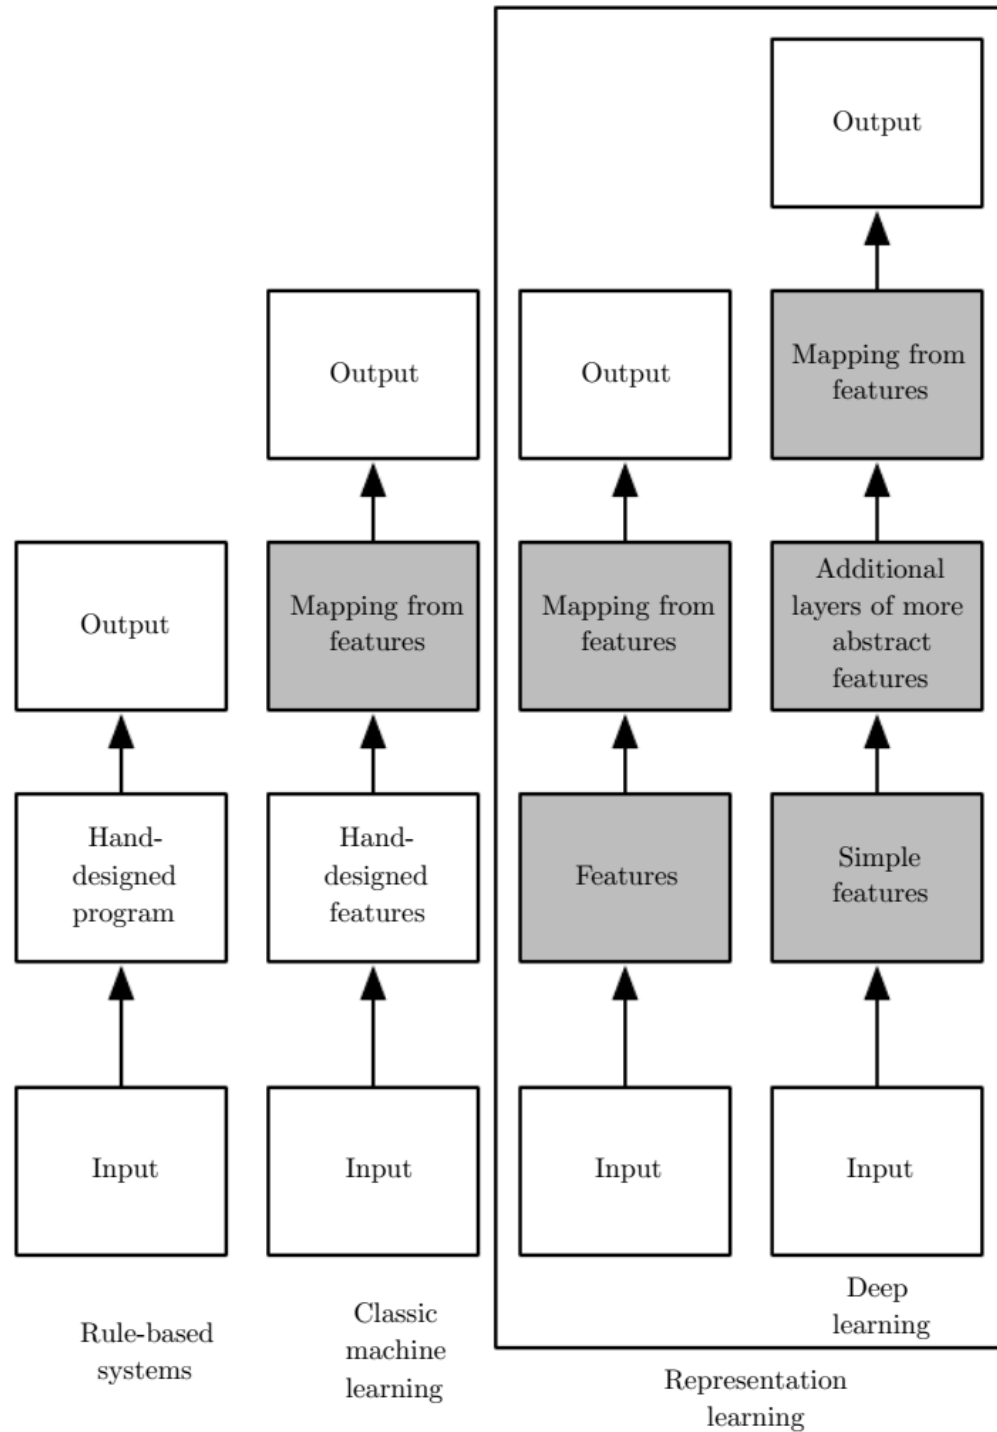
- تابع ضرر (تابع هدف) اندازه‌گیری می‌کند که خروجی‌های شبکه چه مقدار به خروجی‌های مطلوب نزدیک هستند



یادگیری عمیق


- با استفاده از بازخورد سیگنال تابع ضرر، مقدار وزن‌های شبکه در جهت کاهش تابع ضرر برای نمونه فعلی کمی تنظیم می‌شود
- به یک بهینه‌ساز مناسب نیاز داریم





پیش از یادگیری عمیق

- یادگیری عمیق همواره بهترین ابزار برای حل مسئله مورد نظر ما نیست
 - ممکن است داده کافی برای آموزش مناسب شبکه‌های عمیق در اختیار نباشد
 - گاهی یک مسئله با الگوریتم‌های دیگر بهتر حل می‌شود
- در ادامه روش مدل‌سازی احتمالی را بررسی می‌کنیم تا مروری بر نظریه احتمالات داشته باشیم



مدل سازی احتمالی

- بخش هایی از دانش که ما به آنها دسترسی نداریم، متغیرهای غیرقابل مشاهده نامیده می شوند
- در پرتاب سکه، تنها متغیر قابل مشاهده نتیجه پرتاب سکه (شیر یا خط) است
 - آن را به عنوان یک متغیر تصادفی باینری تعریف می کنیم
 - فرض کنید $X = 1$ نشان دهنده شیر آمدن سکه و $X = 0$ نشان دهنده خط آمدن باشد

$$P(X = 1) = p_0$$

$$P(X = 0) = 1 - P(X = 1) = 1 - p_0$$




مدل سازی احتمالی

- به عنوان یک مثال ساده، فرض کنید دو جعبه به رنگ‌های **آبی** و **قرمز** داریم
- در جعبه **آبی** ۱ توپ **سبز** و ۶ توپ **نارنجی** قرار دارد و در جعبه **قرمز** ۳ توپ **سبز** و ۱ توپ **نارنجی**
- به صورت تصادفی یکی از جعبه‌ها را انتخاب می‌کنیم و از درون آن به صورت تصادفی یک توپ را بر می‌داریم

- جعبه انتخاب شده یک متغیر تصادفی است
- توپ انتخاب شده هم یک متغیر تصادفی است


$$Box = \{red, blue\}$$

$$Ball = \{green, orange\}$$



مدل سازی احتمالی

- فرض کنید جعبه قرمز با احتمال ۴۰٪ انتخاب می شود
- احتمال آنکه یک توپ سبز انتخاب شود چقدر است؟
- اگر بدانیم یک توپ نارنجی انتخاب شده است، احتمال آنکه جعبه انتخاب شده آبی باشد چقدر است؟



$$P(\text{Box} = \text{red}) = 0.4$$

$$P(\text{Box} = \text{blue}) = 0.6$$

$$\text{Box} = \{\text{red}, \text{blue}\}$$

$$\text{Ball} = \{\text{green}, \text{orange}\}$$

مدل سازی احتمالی

- برای بدست آوردن قواعد احتمال، یک مثال که شامل دو متغیر تصادفی X و Y است را در نظر بگیرید
- فرض کنید N مشاهده انجام شده است
- احتمال آنکه متغیر تصادفی X برابر با x_i و Y برابر با y_j باشد، احتمال توام (joint) نامیده می شود و برابر است با:

$$P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$$

y_j			n_{ij}	

x_i

مدل سازی احتمالی

- احتمال آنکه مقدار X برابر با x_i باشد مستقل از آنکه Y چه مقداری دارد احتمال حاشیه‌ای (marginal) نامیده می‌شود و برابر است با:

$$P(X = x_i) = \frac{c_i}{N} = \frac{\sum_j n_{ij}}{N} = \sum_{j=1}^L P(X = x_i, Y = y_j)$$

- قاعده جمع احتمال

			c_i	
			n_{ij}	
y_j				r_j
			x_i	

مدل سازی احتمالی

- احتمال شرطی (conditional) برای $Y = y_j$ به شرط $X = x_i$:

$$P(Y = y_j | X = x_i) = \frac{n_{ij}}{c_i}$$

$$P(X = x_i, Y = y_j) = \frac{n_{ij}}{N} = \frac{n_{ij}}{c_i} \frac{c_i}{N}$$

$$= P(Y = y_j | X = x_i) P(X = x_i)$$

- قاعده ضرب احتمال

A contingency table diagram with 3 rows and 5 columns. The columns are labeled x_i at the bottom, and the rows are labeled y_j on the left. A bracket above the columns is labeled c_i , and a bracket to the right of the rows is labeled r_j . The cell at the intersection of the second row and fourth column is labeled n_{ij} .

y_j			n_{ij}	

مدل سازی احتمالی

- قاعده جمع:

$$P(X) = \sum_Y P(X, Y)$$

- قاعده ضرب:

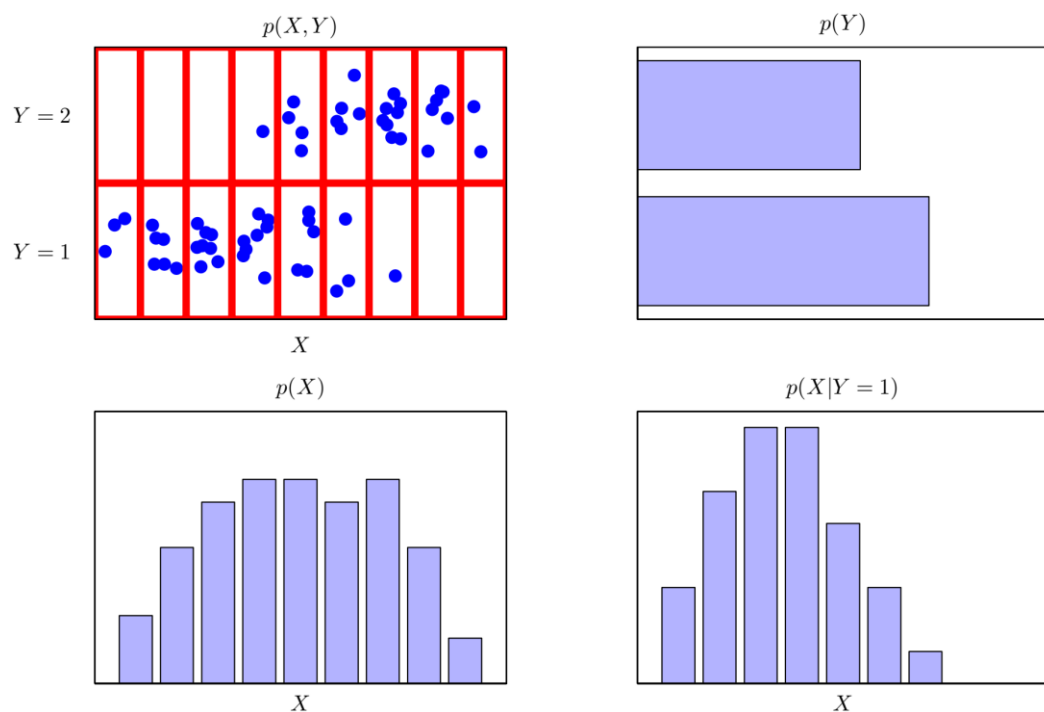
$$P(X, Y) = P(Y|X)P(X)$$

$$= P(Y, X) = P(X|Y)P(Y)$$

- تئوری Bayes:



$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

$$P(X) = \sum_Y P(X|Y)P(Y)$$



مدل سازی احتمالی

- فرض کنید جعبه قرمز با احتمال ۴۰٪ انتخاب می شود
- احتمال آنکه یک توپ سبز انتخاب شود چقدر است؟
- اگر بدانیم یک توپ نارنجی انتخاب شده است، احتمال آنکه جعبه انتخاب شده آبی باشد چقدر است؟



$$Box = \{red, blue\}$$

$$Ball = \{green, orange\}$$


$$P(Box = red) = 0.4$$

$$P(Box = blue) = 0.6$$

مدل سازی احتمالی

- احتمال آنکه یک توپ سبز انتخاب شود چقدر است؟

$$P(\text{Ball} = \text{green}) = P(\text{green}|\text{blue})P(\text{blue}) + P(\text{green}|\text{red})P(\text{red}) = \frac{6}{10} \frac{3}{4} + \frac{4}{10} \frac{1}{4} = \frac{11}{20}$$



$$P(\text{Ball} = \text{orange}) = 9/20$$

$$P(\text{Ball} = \text{green}|\text{Box} = \text{red}) = 2/8$$

$$P(\text{Ball} = \text{green}|\text{Box} = \text{blue}) = 3/4$$

$$P(\text{Box} = \text{red}) = 0.4$$


$$P(\text{Box} = \text{blue}) = 0.6$$

مدل سازی احتمالی

- اگر بدانیم یک توپ نارنجی انتخاب شده است، احتمال آنکه جعبه انتخاب شده آبی باشد چقدر است؟

$$P(\text{Box} = \text{blue} | \text{Ball} = \text{orange}) = \frac{P(\text{orange} | \text{blue})P(\text{blue})}{P(\text{orange})} = \frac{\frac{1}{4} \frac{6}{10}}{\frac{6}{8} \frac{4}{10} + \frac{1}{4} \frac{6}{10}} = \frac{1}{3}$$

$$P(\text{Box} = \text{red} | \text{Ball} = \text{orange}) = \frac{2}{3}$$





$$P(\text{Box} = \text{red}) = 0.4$$

$$P(\text{Box} = \text{blue}) = 0.6$$

مدل سازی احتمالی

- چند مفهوم بسیار هم از تئوری Bayes قابل استخراج است:
 - اگر از ما پرسیده شود کدام جعبه انتخاب شده است قبل از آنکه توپ برداشته شده مشخص شود
 - حداکثر اطلاعات ما همان $P(Box)$ است
 - به $P(Box)$ احتمال پیشین (prior) گفته می شود
 - اگر بدانیم توپ برداشته شده نارنجی است
 - می توانیم با استفاده از تئوری بیز $P(Box|Ball)$ را محاسبه کنیم
 - به $P(Box|Ball)$ احتمال پسین (posterior) گفته می شود



$$P(Box = \text{red}) = 0.4$$

$$P(Box = \text{blue}) = 0.6$$

$$P(\text{red}|\text{orange}) = 2/3$$



$$P(\text{blue}|\text{orange}) = 1/3$$

دسته‌بند Bayes

- دسته‌بند Bayes کلاسی را انتخاب می‌کند که بیشترین احتمال پسین را داشته باشد

$$P(C_i|\mathbf{x}) = \frac{P(\mathbf{x}|C_i)P(C_i)}{P(\mathbf{x})} = \frac{P(\mathbf{x}|C_i)P(C_i)}{\sum_{k=1}^K P(\mathbf{x}|C_k)P(C_k)}$$

choose C_i if $P(C_i|\mathbf{x}) = \max_k P(C_k|\mathbf{x})$



Naïve Bayes

- یک دسته‌بند مبتنی بر تئوری Bayes است که فرض می‌کند ویژگی‌ها مستقل از هم و دارای توزیع نرمال هستند

GAUSSIAN NAIVE BAYES CLASSIFIER

"Gaussian" because this is a normal distribution

This is our prior belief

$$P(\text{class} | \text{data}) = \frac{P(\text{data} | \text{class}) \times P(\text{class})}{P(\text{data})}$$

We don't calculate this in naive bayes classifiers

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$


$$P(X) = \prod P(X^k)$$

$$P(X|Y) = \prod P(X^k|Y)$$

مثال


Person	height (feet)	weight (lbs)	foot size(inches)
male	6	180	12
male	5.92 (5'11")	190	11
male	5.58 (5'7")	170	12
male	5.92 (5'11")	165	10
female	5	100	6
female	5.5 (5'6")	150	8
female	5.42 (5'5")	130	7
female	5.75 (5'9")	150	9

- مسئله: تشخیص مرد یا زن بودن یک انسان
- ویژگی‌ها: قد، وزن و اندازه پا



Person	height (feet)	weight (lbs)	foot size(inches)
male	6	180	12
male	5.92 (5'11")	190	11
male	5.58 (5'7")	170	12
male	5.92 (5'11")	165	10
female	5	100	6
female	5.5 (5'6")	150	8
female	5.42 (5'5")	130	7
female	5.75 (5'9")	150	9

Person	height (feet)	weight (lbs)	foot size(inches)
sample	6	130	8



Person	mean (height)	variance (height)	mean (weight)	variance (weight)	mean (foot size)	variance (foot size)
male	5.855	3.5033×10^{-2}	176.25	1.2292×10^2	11.25	9.1667×10^{-1}
female	5.4175	9.7225×10^{-2}	132.5	5.5833×10^2	7.5	1.6667

Person	height (feet)	weight (lbs)	foot size(inches)
sample	6	130	8

$$\text{posterior (male)} = \frac{P(\text{male}) p(\text{height} \mid \text{male}) p(\text{weight} \mid \text{male}) p(\text{foot size} \mid \text{male})}{\text{evidence}}$$

$$\text{posterior (female)} = \frac{P(\text{female}) p(\text{height} \mid \text{female}) p(\text{weight} \mid \text{female}) p(\text{foot size} \mid \text{female})}{\text{evidence}}$$

$$P(\text{male}) = 0.5$$

$$p(\text{height} \mid \text{male}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{-(6 - \mu)^2}{2\sigma^2}\right) \approx 1.5789,$$

Person	mean (height)	variance (height)	mean (weight)	variance (weight)	mean (foot size)	variance (foot size)
male	5.855	3.5033×10^{-2}	176.25	1.2292×10^2	11.25	9.1667×10^{-1}
female	5.4175	9.7225×10^{-2}	132.5	5.5833×10^2	7.5	1.6667

مثال

Person	height (feet)	weight (lbs)	foot size(inches)
sample	6	130	8

$$\text{posterior (male)} = \frac{P(\text{male}) p(\text{height} \mid \text{male}) p(\text{weight} \mid \text{male}) p(\text{foot size} \mid \text{male})}{\text{evidence}}$$

$$\text{posterior (female)} = \frac{P(\text{female}) p(\text{height} \mid \text{female}) p(\text{weight} \mid \text{female}) p(\text{foot size} \mid \text{female})}{\text{evidence}}$$

$$P(\text{male}) = 0.5$$

$$p(\text{height} \mid \text{male}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{-(6 - \mu)^2}{2\sigma^2}\right) \approx 1.5789,$$

$$p(\text{weight} \mid \text{male}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{-(130 - \mu)^2}{2\sigma^2}\right) = 5.9881 \cdot 10^{-6}$$

$$p(\text{foot size} \mid \text{male}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{-(8 - \mu)^2}{2\sigma^2}\right) = 1.3112 \cdot 10^{-3}$$

مثال

Person	height (feet)	weight (lbs)	foot size(inches)
sample	6	130	8

$$\text{posterior (male)} = \frac{P(\text{male}) p(\text{height} \mid \text{male}) p(\text{weight} \mid \text{male}) p(\text{foot size} \mid \text{male})}{\text{evidence}}$$

$$\text{posterior (female)} = \frac{P(\text{female}) p(\text{height} \mid \text{female}) p(\text{weight} \mid \text{female}) p(\text{foot size} \mid \text{female})}{\text{evidence}}$$

$$\text{posterior numerator (male)} = \text{their product} = 6.1984 \cdot 10^{-9}$$

$$\text{posterior numerator (female)} = \text{their product} = 5.3778 \cdot 10^{-4}$$

Person	mean (height)	variance (height)	mean (weight)	variance (weight)	mean (foot size)	variance (foot size)
male	5.855	3.5033×10^{-2}	176.25	1.2292×10^2	11.25	9.1667×10^{-1}
female	5.4175	9.7225×10^{-2}	132.5	5.5833×10^2	7.5	1.6667